

Regressão Linear Múltipla para Previsão de Pressão Arterial: Um Estudo Comparativo Usando scikit-learn e o Método da Pseudoinversa

Maria Giovanna Gonçalves Sales
Faculdade de Tecnologia
Universidade Federal do Amazonas
Manaus, Brasil
maria.sales@icomp.ufam.edu.br

Abstract—Este trabalho apresenta a aplicação da regressão linear múltipla para prever a pressão arterial máxima de pacientes hospitalares utilizando quatro variáveis preditoras: sexo, idade, peso e tabagismo. O conjunto de dados *hospital* do MATLAB, contendo 100 observações, foi utilizado. A avaliação do modelo foi realizada por meio de validação cruzada 5-fold, utilizando o coeficiente de correlação de Pearson e o Erro Quadrático Médio (MSE) como métricas de desempenho. Duas abordagens de treinamento foram comparadas: o estimador de alto nível `LinearRegression` da biblioteca `scikit-learn` e uma solução analítica baseada na matriz pseudoinversa de Moore–Penrose. Os resultados mostram que ambos os métodos produzem previsões equivalentes. A implementação completa dos métodos se encontra em: <https://colab.research.google.com/drive/17jvdbf9EWiSlzlbizrL0licBgJJoRIET?usp=sharing>.

Index Terms—regressão linear múltipla, previsão de pressão arterial, validação cruzada, pseudoinversa, `scikit-learn`

I. INTRODUÇÃO

A hipertensão é uma das doenças crônicas mais prevalentes em todo o mundo, afetando aproximadamente um em cada quatro adultos e sendo responsável por cerca de 13% das mortes globalmente [1]. A capacidade de prever a pressão arterial de um paciente a partir de características demográficas e clínicas possui grande relevância para a medicina preventiva, permitindo a identificação de indivíduos de alto risco antes que a doença se estabeleça. A regressão linear múltipla é uma das técnicas de aprendizado supervisionado mais clássicas e interpretáveis, expressando uma variável de saída contínua como uma combinação linear ponderada de características de entrada [2]. Apesar da crescente popularidade de modelos complexos de aprendizado de máquina, os modelos lineares continuam sendo uma forte base de referência em ambientes clínicos devido à sua transparência e facilidade de implantação.

Este trabalho aplica a regressão linear múltipla para prever a pressão arterial máxima (sistólica) de pacientes hospitalares usando quatro variáveis preditoras: sexo, idade, peso e tabagismo (status de fumante). O protocolo experimental segue o fluxo de avaliação padrão em reconhecimento de padrões: validação cruzada 5-fold com o coeficiente de Pearson e o MSE como métricas. Duas implementações são comparadas –

o estimador da biblioteca `scikit-learn` e uma solução programada manualmente utilizando a pseudoinversa.

Trabalhos relacionados exploraram a previsão da pressão arterial por meio de abordagens tradicionais de regressão e aprendizado de máquina. Chowdhury et al. [3] conduziram uma revisão sistemática de 52 estudos e descobriram que a idade, o índice de massa corporal e o sexo estão entre os preditores mais comuns, espelhando as variáveis utilizadas neste estudo. Austin et al. [4] compararam a regressão linear de mínimos quadrados ordinários com outros cinco métodos de aprendizado estatístico e de máquina para prever a pressão arterial em pacientes cardiovasculares hospitalizados, utilizando o MSE e o coeficiente de Pearson ao quadrado como métricas de avaliação. Martinez-Ríos et al. [5] revisaram técnicas de aprendizado de máquina para detecção de hipertensão e estimativa da pressão arterial a partir de dados clínicos e fisiológicos, observando uma escassez de estudos que combinam variáveis sociodemográficas com sinais fisiológicos.

II. METODOLOGIA

A. Conjunto de Dados e Pré-processamento

Foi utilizado o conjunto de dados *hospital* do MATLAB, contendo 100 observações de pacientes. As seguintes colunas foram selecionadas: *Sex* (Sexo), *Age* (Idade), *Weight* (Peso) e *Smoker* (Fumante) como variáveis preditoras (x), e *Blood-Pressure_1* como a variável alvo (y). A variável categórica *Sex* foi codificada numericamente (0 para masculino, 1 para feminino).

B. Validação Cruzada 5-Fold

O conjunto de dados foi particionado em $k = 5$ subconjuntos (*folds*) de tamanho aproximadamente igual (≈ 20 registros cada) usando divisão aleatória estratificada com uma semente fixa `random_state=42`.

Em cada iteração $i \in \{1, \dots, 5\}$, quatro *folds* (≈ 80 registros) foram utilizados para treinamento e um *fold* (≈ 20 registros) para teste, garantindo que cada observação aparecesse no conjunto de teste exatamente uma vez. O processo geral é ilustrado na Fig. 1.




Fig. 1. Fluxo de trabalho geral.

C. Métricas de Desempenho

Para cada *fold*, duas métricas foram calculadas entre os valores verdadeiros y_i e os valores previstos $\hat{y}_i$:

Coefficiente de Correlação de Pearson

$$r = \frac{\sum_{i=1}^n (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2 \sum_{i=1}^n (\hat{y}_i - \bar{\hat{y}})^2}}, \quad (1)$$

onde $r \in [-1, 1]$ e valores próximos a 1 indicam uma forte concordância linear positiva entre as previsões e os valores reais.

Erro Quadrático Médio (MSE)

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2. \quad (2)$$

Valores mais baixos de MSE indicam melhor precisão preditiva.

D. Regressão Linear com scikit-learn

A primeira abordagem utiliza a classe `sklearn.linear_model.LinearRegression`, que minimiza a soma residual dos quadrados para estimar o vetor de pesos $\mathbf{w}$ internamente, por meio de um solucionador otimizado de mínimos quadrados. Nenhum ajuste de hiperparâmetros foi necessário.

E. Método da Pseudoinversa

A segunda abordagem implementa a solução analítica ensinada na disciplina. Para N observações e p variáveis preditoras, o modelo é expresso como

$$\mathbf{y} = \mathbf{X}\mathbf{w}, \quad (3)$$

onde $\mathbf{X} \in \mathbb{R}^{N \times (p+1)}$ inclui uma coluna de uns para representar o termo de viés (intercepto) k , e $\mathbf{w} = [w_1, w_2, \dots, w_p, k]^\top$. Como $p \ll N$, o sistema é superdeterminado e é resolvido no sentido dos mínimos quadrados por meio da pseudoinversa de Moore–Penrose $\mathbf{X}^+$:

$$\mathbf{w} = \mathbf{X}^+ \mathbf{y} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (4)$$

As previsões em dados não vistos são obtidas através de $\hat{\mathbf{y}} = \mathbf{X}_{\text{teste}} \mathbf{w}$. O método foi implementado em NumPy usando `np.linalg.inv` em conjunto com a multiplicação de matrizes, seguindo fielmente a equação (4).

III. RESULTADOS E DISCUSSÃO

As Tabelas I e II apresentam, respectivamente, o coeficiente de Pearson e o MSE obtidos em cada *fold* para o estimador do scikit-learn e para a implementação baseada na pseudoinversa.

TABLE I
RESULTADOS POR FOLD – LINEARREGRESSION (SCIKIT-LEARN)

Fold	Pearson (r)	MSE
1	0.5190	32.4615
2	0.6989	18.2036
3	0.7297	15.1829
4	0.8383	28.3679
5	0.6405	28.6908
Média	0.6853	24.5813

TABLE II
RESULTADOS POR FOLD – MÉTODO DA PSEUDOINVERSA

Fold	Pearson (r)	MSE
1	0.5190	32.4615
2	0.6989	18.2036
3	0.7297	15.1829
4	0.8383	28.3679
5	0.6405	28.6908
Média	0.6853	24.5813

Observando os resultados fold a fold, nota-se uma variação entre as partições, o que é esperado em conjuntos de dados pequenos, pois a composição de cada subconjunto de teste influencia significativamente as métricas.

O *fold* 4 apresentou o melhor desempenho, com $r = 0,8383$. O MSE correspondente, de 28,37, embora não seja o menor, ainda se encontra em um patamar aceitável.

O *fold* 3 obteve o menor MSE (15,18), sugerindo que os padrões presentes naquele subconjunto de teste foram bem capturados pelo modelo treinado nas demais amostras.

Em contrapartida, o *fold* 1 apresentou o pior desempenho: $r = 0,5190$ e $MSE = 32,46$. O valor de Pearson sugere que o subconjunto de teste desse *fold* continha perfis de pacientes menos representados nos dados de treino.

De forma geral, o Pearson médio de **0,6853** indica uma correlação moderada, e o MSE médio de **24,58** (em mmHg²) reflete um erro médio absoluto aproximado de cerca de 4–5 mmHg na escala original da pressão arterial. Esse nível de desempenho é razoável para um modelo linear simples com apenas quatro variáveis preditoras.

A. Comparação entre os métodos

Os resultados das duas abordagens foram numericamente idênticos em todos os *folds*. Ambos os métodos resolvem o mesmo problema de mínimos quadrados ordinários e, para um conjunto de dados bem condicionado como o utilizado, chegam à mesma solução ótima.

A diferença entre os métodos está apenas na forma como o cálculo é realizado. A implementação manual utiliza a fórmula analítica direta e faz inversão explícita de matrizes. O scikit-learn, por sua vez, utiliza internamente a *Decomposição em Valores Singulares* (SVD) e obtém os pesos sem inverter matrizes diretamente, sendo numericamente mais estável.

No entanto, como as variáveis preditoras do conjunto hospitalar não apresentam dependência linear entre si, ambas as abordagens produziram resultados equivalentes.

IV. CONCLUSÃO

Este trabalho implementou e comparou duas abordagens para regressão linear múltipla aplicada à predição da pressão arterial máxima de pacientes a partir das variáveis sexo, idade, peso e tabagismo. A avaliação foi conduzida por meio de validação cruzada com 5 *folds*, utilizando o coeficiente de Pearson e o MSE como métricas de desempenho.

Os resultados confirmaram que a implementação manual via pseudoinversa de Moore–Penrose e o estimador `LinearRegression` do scikit-learn são matematicamente equivalentes, produzindo valores idênticos em todas as partições.

O Pearson médio de 0,6853 e o MSE médio de 24,58 mmHg² são satisfatórios para um modelo linear com quatro preditores, mas o uso de variáveis clínicas adicionais poderia aumentar o poder explicativo do modelo.

Do ponto de vista prático, o scikit-learn é preferível por sua estabilidade numérica via SVD, especialmente em cenários com variáveis correlacionadas ou matrizes mal condicionadas. Por outro lado, a implementação manual foi essencial para compreender a base matemática da regressão linear, tornando explícita a relação entre a solução analítica e o processo de minimização do erro quadrático.

REFERENCES

- [1] S. Mendis, P. Puska, and B. Norrving, Eds., *Global Atlas on Cardiovascular Disease Prevention and Control*. Geneva: World Health Organization, 2011.
- [2] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York: Springer, 2006.
- [3] M. Z. I. Chowdhury, I. Naeem, H. Quan et al., “Prediction of hypertension using traditional regression and machine learning models: A systematic review and meta-analysis,” *PLoS ONE*, vol. 17, no. 4, p. e0266334, Apr. 2022.
- [4] P. C. Austin, F. E. Harrell Jr., D. S. Lee, and E. W. Steyerberg, “Empirical analyses and simulations showed that different machine and statistical learning methods had differing performance for predicting blood pressure,” *Sci. Rep.*, vol. 12, no. 9312, Jun. 2022.
- [5] E. Martinez-Ríos, L. Montesinos, M.-C. Alfaro-Ponce, and L. Pecchia, “A review of machine learning in hypertension detection and blood pressure estimation based on clinical and physiological data,” *Biomed. Signal Process. Control*, vol. 68, p. 102813, Jul. 2021.