

Regressão Logística para Classificação de Câncer de Ovário

Maria Giovanna Gonçalves Sales
Faculdade de Tecnologia
Universidade Federal do Amazonas
Manaus, Brasil
maria.sales@icomp.ufam.edu.br

Abstract—Este trabalho apresenta a aplicação da regressão logística com uma camada para classificar pacientes com e sem câncer de ovário, utilizando dados de espectrometria de massa. O conjunto de dados é composto por 216 pacientes, cada um descrito por 100 intensidades de íons medidas para diferentes valores de massa-carga. O modelo foi treinado com 80% dos dados e avaliado nos 20% restantes, sem validação cruzada. Como técnica opcional de seleção de características, foi aplicado o ANOVA F-score para reduzir o conjunto de features de 100 para 50. O modelo com todas as features obteve acurácia de 95,45%, sensibilidade de 92,00% e especificidade de 100,00%, evidenciando alta capacidade de discriminação entre as classes. A implementação completa do trabalho se encontra em: https://colab.research.google.com/drive/1Gm_Le-Lh2P3ZdV1HMSAwrANApkV_uhmT?usp=sharing.

Index Terms—regressão logística, câncer de ovário, espectrometria de massa, classificação binária, seleção de características

I. INTRODUÇÃO

O câncer de ovário é uma das neoplasias malignas mais letais do sistema reprodutor feminino, em grande parte devido à ausência de sintomas nas fases iniciais e à falta de métodos de triagem amplamente eficazes [1]. Técnicas de espectrometria de massa têm emergido como uma abordagem promissora para a identificação de biomarcadores séricos capazes de distinguir pacientes doentes de indivíduos saudáveis, gerando perfis de alta dimensionalidade que exigem métodos computacionais robustos para análise.

No contexto do aprendizado de máquina aplicado à saúde, a regressão logística tem demonstrado valor considerável como classificador linear interpretável. Joshi e Dhakal [2] utilizaram regressão logística para prever diabetes tipo 2 em mulheres da população Pima Indian. Em um domínio próximo ao deste trabalho, Sans et al. [3] aplicaram regressão logística com regularização Lasso para classificação de tecidos ovarianos a partir de imagens de espectrometria de massa por ionização ambiente, diferenciando tecidos normais de carcinomas serosos de alto grau com resultados promissores de acurácia e especificidade.

Este trabalho implementa um regressor logístico de uma camada para a tarefa de classificação binária entre pacientes com câncer de ovário e pacientes normais, utilizando a base de dados de espectrometria de massa disponibilizada pelo professor. São reportadas métricas de acurácia, sensibilidade

e especificidade, e é aplicada uma etapa opcional de seleção de características via ANOVA F-score.

II. METODOLOGIA

A. Conjunto de Dados e Pré-processamento

Os dados utilizados provêm de dois arquivos: *ovarianInputs*, uma matriz 216×100 contendo intensidades de íons para 100 valores de massa-carga, e *ovarianTargets*, uma matriz 216×2 com os rótulos de classe — $[1, 0]$ para câncer e $[0, 1]$ para paciente normal. O conjunto contém 121 pacientes com câncer e 95 pacientes normais. Ambos os arquivos foram convertidos para o formato CSV antes do processamento.

As *features* foram normalizadas para o intervalo $[0, 1]$ utilizando a transformação Min-Max:

$$x_{\text{norm}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (1)$$

Essa normalização remove a influência das escalas originais de cada *feature* sobre o processo de otimização.

B. Divisão Treino/Teste

O conjunto de dados foi dividido em 80% para treinamento (172 amostras) e 20% para teste (44 amostras), utilizando amostragem estratificada (*stratify=y*) com semente aleatória fixa (*random_state=42*), garantindo que a proporção entre as classes fosse preservada em ambas as partições. Não foi realizada validação cruzada.

C. Modelo: Regressão Logística com Uma Camada

A regressão logística é um classificador linear que modela a probabilidade de pertencimento a uma classe. O modelo é composto por duas etapas:

(i) **Combinação linear** das *features* de entrada:

$$z = \mathbf{w}^T \mathbf{x} + b \quad (2)$$

onde $\mathbf{w} \in \mathbb{R}^p$ é o vetor de pesos aprendidos, b é o viés (intercepto) e $\mathbf{x} \in \mathbb{R}^p$ é o vetor de *features* de uma amostra.

(ii) **Função de ativação sigmoid**, que mapeia z para o intervalo $(0, 1)$:

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (3)$$

O valor $\hat{y}$ representa a probabilidade estimada de o paciente pertencer à classe positiva (câncer). A classe predita é determinada pelo limiar de 0,5: se $\hat{y} \geq 0,5$, o paciente é classificado como portador de câncer; caso contrário, como normal. A fronteira de decisão resultante é um hiperplano linear no espaço de *features*, razão pela qual a regressão logística é classificada como um método de classificação linear.

Os parâmetros w e b são estimados pela maximização da log-verossimilhança (equivalente à minimização da entropia cruzada binária) via otimização numérica. A implementação utilizada foi a classe `LogisticRegression` da biblioteca *scikit-learn*, com `max_iter=1000` e `random_state=42`.

D. Métricas de Avaliação

Foram calculadas três métricas a partir da matriz de confusão, sendo VP o número de verdadeiros positivos, VN o de verdadeiros negativos, FP o de falsos positivos e FN o de falsos negativos:

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN} \quad (4)$$

$$\text{Sensibilidade} = \frac{VP}{VP + FN} \quad (5)$$

$$\text{Especificidade} = \frac{VN}{VN + FP} \quad (6)$$

A sensibilidade mede a proporção de pacientes com câncer corretamente identificados (recall da classe positiva), enquanto a especificidade mede a proporção de pacientes normais corretamente classificados. Em triagem oncológica, a sensibilidade é especialmente crítica, pois falsos negativos podem ter consequências graves para o paciente.

E. Seleção de Características via ANOVA *F*-score

Como etapa opcional, foi aplicada a seleção das 50 *features* mais discriminativas entre as 100 disponíveis, utilizando o ANOVA *F*-score. O *F*-score de uma *feature* é definido como a razão entre a variância entre grupos (classes) e a variância intra-grupo:

$$F = \frac{\text{variância entre grupos}}{\text{variância dentro dos grupos}} \quad (7)$$

Features com maior valor de *F* são mais discriminativas entre as classes. A seleção foi realizada ajustando o critério exclusivamente nos dados de treinamento, com o método `SelectKBest(f_classif, k=50)` do *scikit-learn*, e a mesma transformação foi aplicada ao conjunto de teste.

III. RESULTADOS E DISCUSSÃO

A Tabela I apresenta o comparativo de desempenho do modelo de regressão logística com 100 *features* (configuração completa) e com 50 *features* selecionadas pelo ANOVA *F*-score.

Com todas as 100 *features*, o modelo alcançou acurácia de 95,45%, sensibilidade de 92,00% e especificidade de 100,00%. A especificidade perfeita indica que nenhum paciente normal

TABLE I
COMPARATIVO DE DESEMPENHO: 100 vs. 50 *Features*

Métrica	100 <i>features</i>	50 <i>features</i>
Acurácia	95,45%	88,64%
Sensibilidade	92,00%	88,00%
Especificidade	100,00%	89,47%

foi incorretamente classificado como portador de câncer (zero falsos positivos). Os dois erros de classificação foram falsos negativos — pacientes com câncer classificados como normais — o que é clinicamente indesejável, mas esperado em um conjunto de dados pequeno.

A matriz de confusão correspondente foi:

$$C = \begin{pmatrix} 19 & 0 \\ 2 & 23 \end{pmatrix}$$

onde as linhas representam a classe real (Normal, Câncer) e as colunas a classe predita.

Com a redução para 50 *features*, o desempenho diminuiu para acurácia de 88,64%, sensibilidade de 88,00% e especificidade de 89,47%. Esse declínio sugere que parte das *features* eliminadas pelo ANOVA *F*-score continha informação relevante para a classificação, embora com menor poder discriminativo individual. O ANOVA *F*-score avalia *features* de forma independente e não captura interações entre variáveis, o que pode levar à eliminação de *features* que, em conjunto, contribuem para a discriminação entre as classes.

De forma geral, os resultados demonstram que a regressão logística é altamente eficaz para esta tarefa.

IV. CONCLUSÃO

Este trabalho implementou um regressor logístico de uma camada para a classificação binária de pacientes com e sem câncer de ovário a partir de dados de espectrometria de massa. O modelo, treinado com 80% dos dados e avaliado nos 20% restantes, alcançou acurácia de 95,45%, sensibilidade de 92,00% e especificidade de 100,00% com o conjunto completo de 100 *features*. A redução para 50 *features* via ANOVA *F*-score resultou em queda de desempenho, indicando que as *features* descartadas contribuíam de forma complementar para a classificação.

Os resultados confirmam a adequação da regressão logística como classificador linear interpretável para dados biomédicos de alta dimensionalidade.

Trabalhos futuros poderiam explorar técnicas de seleção de *features* que considerem interações entre variáveis, como seleção baseada em modelos ou métodos de seleção sequencial.

REFERENCES

- [1] World Health Organization, *World Cancer Report 2020*. Geneva: WHO, 2020.
- [2] R. D. Joshi e C. K. Dhakal, "Predicting Type 2 Diabetes Using Logistic Regression and Machine Learning Approaches," *Int. J. Environ. Res. Public Health*, vol. 18, no. 14, p. 7346, Jul. 2021.

- [3] M. Sans *et al.*, “Metabolic Markers and Statistical Prediction of Serous Ovarian Cancer Aggressiveness by Ambient Ionization Mass Spectrometry Imaging,” *Cancer Res.*, vol. 77, no. 11, pp. 2903–2913, Jun. 2017.