

Comparação de Modelos de *Random Forest* para Previsão de Temperatura Máxima com Análise de Importância de Variáveis

Maria Giovanna Gonçalves Sales
Faculdade de Tecnologia
Universidade Federal do Amazonas
Manaus, Brasil
maria.sales@icomp.ufam.edu.br

Abstract—Este trabalho aplica o algoritmo *Random Forest* para a previsão da temperatura máxima diária na cidade de *Seattle*, utilizando dados históricos de clima referentes a seis anos consecutivos. Foram avaliados três modelos com diferentes configurações de hiperparâmetros, utilizando as variáveis *year*, *ws_1*, *temp_2*, *temp_1* e *average* como preditores. Os dados foram normalizados com padronização *z-score* e divididos em 75% para treino e 25% para teste. O melhor modelo obtido alcançou um erro absoluto médio (MAE) de 3,75 e um erro quadrático médio (MSE) de 22,73, com coeficiente de determinação R^2 de 0,860. A análise de importância das variáveis revelou que a temperatura máxima do dia anterior (*temp_1*) é, de longe, o preditor mais relevante para o problema. A implementação completa está disponível em: <https://colab.research.google.com/drive/12UT2ZYzYtWEklzIYcTLeJl8Tji-isinS?usp=sharing>.

Index Terms—*random forest*, previsão de temperatura, aprendizado de máquina, importância de variáveis, regressão

I. INTRODUÇÃO

A previsão de temperatura é um problema de grande relevância prática, com aplicações que vão desde o planejamento agrícola e energético até a gestão de eventos e saúde pública. A temperatura máxima diária, em especial, é um indicador importante para sistemas de alerta de calor e para a tomada de decisão em atividades ao ar livre. Com a crescente disponibilidade de séries históricas de dados meteorológicos, métodos de aprendizado de máquina têm sido amplamente explorados para a construção de modelos preditivos mais robustos do que os modelos físicos tradicionais.

Entre os algoritmos de aprendizado de máquina utilizados para tarefas de regressão, o *Random Forest* destaca-se por sua capacidade de lidar com dados ruidosos, evitar *overfitting* por meio da combinação de múltiplas árvores de decisão e fornecer estimativas de importância de variáveis de forma nativa. Breiman [1] formalizou o algoritmo e demonstrou seus ganhos de generalização em relação a árvores de decisão individuais. Trabalhos posteriores confirmaram sua eficácia em problemas de previsão meteorológica. Grömping [2], por exemplo, analisou em profundidade as métricas de importância de variáveis em florestas aleatórias, demonstrando que a permutação de importância e a impureza de Gini são instrumentos confiáveis para a interpretação do modelo — o que é especialmente

relevante em aplicações em que a compreensão das variáveis preditoras é tão importante quanto a acurácia da previsão.

O objetivo deste trabalho é comparar três configurações distintas de hiperparâmetros do *Random Forest* para a previsão da temperatura máxima diária em *Seattle*, utilizando dados de 2011 a 2016, e analisar a contribuição de cada variável preditora em cada modelo.

II. METODOLOGIA

A. Base de dados

A base de dados utilizada é a *temps_extended.xlsx*, que contém 2.191 registros diários referentes a seis anos de observações meteorológicas em *Seattle* (2011–2016). A variável alvo é *actual*, correspondente à temperatura máxima verificada em cada dia, medida em graus Fahrenheit.

As cinco variáveis preditoras selecionadas, conforme o enunciado do trabalho, são:

- *year*: ano em que o registro ocorreu;
- *ws_1*: velocidade média do vento um dia antes;
- *temp_2*: temperatura máxima dois dias antes;
- *temp_1*: temperatura máxima um dia antes;
- *average*: histórico de média de temperaturas máximas.

B. Pré-processamento

Os valores ausentes foram removidos da base. A coluna categórica *weekday* foi convertida para valores numéricos por meio de *LabelEncoder*, embora não tenha sido utilizada como preditora nos experimentos.

As cinco variáveis preditoras numéricas foram normalizadas com o método de padronização *z-score* (média zero e desvio padrão unitário), utilizando o *StandardScaler* da biblioteca *scikit-learn*. A normalização é importante para garantir que variáveis em escalas diferentes não introduzam viés no processo de seleção de atributos.

C. Divisão dos dados

Os dados foram divididos aleatoriamente em 75% para treinamento (1.643 amostras) e 25% para teste (548 amostras), com semente aleatória fixada (*random_state* = 42) para garantir reprodutibilidade.

D. Modelos avaliados

Foram treinados três modelos de *Random Forest* com diferentes configurações de hiperparâmetros, utilizando a classe *RandomForestRegressor* do *scikit-learn*. A Tabela I resume os hiperparâmetros de cada modelo.

TABLE I
HIPERPARÂMETROS DOS TRÊS MODELOS AVALIADOS

Parâmetro	Modelo 1	Modelo 2	Modelo 3
<i>n_estimators</i>	600	200	400
<i>max_depth</i>	10	3	50
<i>min_samples_leaf</i>	1	4	2
<i>min_samples_split</i>	10	5	2
<i>bootstrap</i>	True	True	False

Os modelos foram definidos de forma que cada configuração explorasse uma região distinta do espaço de hiperparâmetros.

O Modelo 1 representa uma configuração balanceada, com profundidade moderada (10), maior número de estimadores (600) e *bootstrap* ativo.

O Modelo 2 é mais restritivo, com profundidade máxima de 3, o que resulta em árvores mais rasas e um modelo com maior viés.

O Modelo 3 explora árvores com profundidade muito elevada (50) e sem *bootstrap*, com os menores valores de *min_samples_leaf* e *min_samples_split*, o que tende a aumentar a variância e o risco de *overfitting*.

E. Métricas de avaliação

O desempenho de cada modelo foi avaliado no conjunto de teste pelas seguintes métricas: erro quadrático médio (MSE), raiz do erro quadrático médio (RMSE), erro absoluto médio (MAE) e coeficiente de determinação (R^2).

O MAE mede o erro médio absoluto em graus Fahrenheit, sendo de interpretação direta. O MSE penaliza erros grandes de forma quadrática. O R^2 indica a proporção da variância da variável alvo explicada pelo modelo, variando de 0 a 1.

Para cada modelo, foi também calculada a importância de cada variável preditora com base na redução média de impureza (*mean decrease in impurity*).

III. RESULTADOS E DISCUSSÃO

A. Desempenho dos modelos

A Tabela II apresenta as métricas de desempenho dos três modelos no conjunto de teste.

TABLE II
MÉTRICAS DE DESEMPENHO NO CONJUNTO DE TESTE

Modelo	MSE	RMSE	MAE	R^2
Modelo 1	22,73	4,77	3,75	0,860
Modelo 2	23,37	4,83	3,73	0,856
Modelo 3	42,89	6,55	5,12	0,736

O Modelo 1 obteve o melhor desempenho em todas as métricas, com MSE de 22,73, RMSE de 4,77, MAE de 3,75

e R^2 de 0,860. Isso indica que o modelo explica aproximadamente 86% da variância da temperatura máxima, com um erro médio de cerca de 3,75°F.

O Modelo 2 apresentou desempenho ligeiramente inferior ao Modelo 1, com MSE de 23,37 e R^2 de 0,856, o que sugere que a restrição de profundidade máxima igual a 3 introduz viés sem ganhos expressivos de generalização.

O Modelo 3 teve o pior desempenho, com MSE de 42,89 e R^2 de 0,736. A combinação de ausência de *bootstrap* com profundidade muito elevada (50) e valores mínimos de *min_samples_leaf* e *min_samples_split* resultou em *overfitting* severo e menor capacidade de generalização para dados não vistos.

Os experimentos realizados e a comparação entre os modelos evidenciaram que o uso de *bootstrap* é um fator determinante para o desempenho: os dois modelos que utilizam *bootstrap* (Modelos 1 e 2) apresentaram resultados consideravelmente superiores ao Modelo 3, que o desativou.

B. Importância das variáveis

A Tabela III apresenta a importância relativa de cada variável preditora para os três modelos.

TABLE III
IMPORTÂNCIA DAS VARIÁVEIS PREDITORAS POR MODELO

Variável	Modelo 1	Modelo 2	Modelo 3
<i>temp_1</i>	0,878	0,963	0,871
<i>average</i>	0,071	0,037	0,061
<i>ws_1</i>	0,025	0,000	0,033
<i>temp_2</i>	0,016	0,000	0,020
<i>year</i>	0,010	0,000	0,016

As Figs. 1, 2 e 3 ilustram a importância das variáveis para cada modelo individualmente, e a Fig. 4 apresenta a comparação entre os três modelos.




Fig. 1. Importância das variáveis preditoras no Modelo 1.

Em todos os modelos, a variável *temp_1* — temperatura máxima do dia anterior — é, de longe, o preditor mais importante, com importância superior a 0,87 em todos os casos. Esse resultado é coerente com a natureza do problema: a temperatura de um dia é fortemente correlacionada com a do dia imediatamente anterior.

IV. CONCLUSÃO

Este trabalho avaliou três configurações do algoritmo *Random Forest* para a previsão da temperatura máxima diária em *Seattle*, usando dados históricos de clima. O Modelo 1, com 600 estimadores, profundidade máxima de 10 e uso de *bootstrap*, obteve o melhor desempenho, com R^2 de 0,860 e MAE de 3,75°F. A normalização dos dados e a seleção cuidadosa de hiperparâmetros contribuíram para a qualidade dos resultados. A análise de importância revelou que a temperatura máxima do dia anterior (*temp_1*) é, consistentemente, o preditor dominante nos três modelos, seguida pela média histórica de temperaturas máximas (*average*).

Os experimentos também evidenciaram que o parâmetro *bootstrap* exerce grande influência no desempenho: os modelos com *bootstrap* ativo (Modelos 1 e 2) superaram substancialmente o Modelo 3, que o desativou, confirmando que a amostragem com reposição é fundamental para a estabilidade da floresta aleatória.

Como trabalho futuro, seria interessante avaliar o impacto da remoção da variável *temp_1* — dada sua dominância quase total — e verificar como o melhor modelo se comporta quando forçado a aprender a partir das variáveis de menor importância, potencialmente revelando relações latentes entre as demais preditoras e a temperatura máxima.

Além disso, a aplicação de busca sistemática por hiperparâmetros via *GridSearchCV* poderia identificar configurações ainda mais precisas.

REFERENCES

- [1] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [2] U. Grömping, "Variable importance assessment in regression: linear regression versus random forest," *The American Statistician*, vol. 63, no. 4, pp. 308–319, 2009.




Fig. 2. Importância das variáveis preditoras no Modelo 2.




Fig. 3. Importância das variáveis preditoras no Modelo 3.

A variável *average*, que representa o histórico de média de temperaturas máximas, ocupa a segunda posição em importância (0,071 no Modelo 1), refletindo a sazonalidade climática da região.

As demais variáveis — *ws_1*, *temp_2* e *year* — têm contribuição marginal. No Modelo 2, com profundidade máxima de 3, as variáveis *ws_1*, *temp_2* e *year* apresentaram importância praticamente nula, o que indica que as divisões disponíveis nas árvores rasas foram inteiramente consumidas pelas variáveis mais informativas.

A dominância de *temp_1* é consistente entre todos os modelos e independente dos hiperparâmetros escolhidos, conforme evidenciado nas Figs. 1, 2, 3 e 4.




Fig. 4. Comparação da importância das variáveis entre os três modelos.