

Utilizando Redes Convolutivas para Reconhecimento Facial na Base ORL

Inteligência Artificial – 2026/1

Maria Giovanna Gonçalves Sales

1 Base de Dados

A base ORL (Olivetti Research Laboratory) contém 400 imagens em escala de cinza de 40 indivíduos (10 imagens por pessoa), com resolução de 92×112 pixels. As imagens variam em iluminação, expressão facial e presença de óculos, capturadas sobre fundo negro homogêneo. A divisão adotada foi de **70%** para treinamento (280 amostras) e **30%** para teste (120 amostras), de forma estratificada por indivíduo.

2 Arquiteturas das Redes

Foram implementadas duas arquiteturas de redes neurais convolutivas (CNNs) utilizando TensorFlow/Keras, ambas recebendo como entrada imagens em escala de cinza com dimensão $92 \times 112 \times 1$ e produzindo uma distribuição de probabilidade sobre as 40 classes via *softmax*.

2.1 Arquitetura 1

A Arquitetura 1 é composta por um único bloco convolucional seguido de uma camada totalmente conectada:

CONV $\rightarrow$ BATCH $\rightarrow$ RELU $\rightarrow$ POOLING $\rightarrow$ FULLCONNECT $\rightarrow$ SOFTMAX

O bloco convolutivo utiliza 16 filtros de tamanho 3×3 com passo 2 e *padding same*, seguido de normalização em lote (*Batch Normalization*), ativação ReLU e *Max Pooling* com janela 4×4 . Após o achatamento (*Flatten*), uma camada densa de 64 neurônios com ReLU e *Dropout* de 0,5 antecede a camada de saída com 40 neurônios e ativação *softmax*. A regularização L2 ($\lambda = 10^{-4}$) é aplicada aos pesos convolutivos e densos.

2.2 Arquitetura 2

A Arquitetura 2 empilha três blocos convolutivos, aumentando progressivamente o número de filtros, seguidos de uma camada totalmente conectada maior:

$[\text{CONV} \rightarrow \text{BATCH} \rightarrow \text{RELU} \rightarrow \text{POOLING}]^3 \rightarrow \text{FULLCONNECT} \rightarrow \text{SOFTMAX}$

Os três blocos utilizam, respectivamente, 32, 64 e 128 filtros de tamanho 3×3 , com passo 2. Cada bloco é seguido de *Batch Normalization*, ReLU e *Max Pooling* 2×2 .

Após o achatamento, uma camada densa de 256 neurônios com ReLU e *Dropout* de 0,5 precede a camada de saída com 40 neurônios e *softmax*. A regularização L2 ($\lambda = 10^{-4}$) é aplicada em todas as camadas treináveis.

3 Hiperparâmetros

A Tabela 1 resume os hiperparâmetros utilizados no treinamento de ambas as redes.

Tabela 1: Hiperparâmetros de treinamento

Hiperparâmetro	Arquitetura 1	Arquitetura 2
Épocas	60	60
Tamanho do <i>batch</i>	16	16
Otimizador	Adam	Adam
Função de perda	Entropia cruzada categórica	Entropia cruzada categórica
<i>Dropout</i>	0,5	0,5
Regularização L2 (λ)	10^{-4}	10^{-4}
Filtros (blocos conv.)	16	32 / 64 / 128
Tamanho do kernel	3×3	3×3
<i>Pooling</i>	4×4	2×2
Neurônios FC	64	256
<i>Seed</i> de reprodutibilidade	42	42

4 Resultados

4.1 Acurácia ao longo do treinamento




Figura 1: Acurácia de treino e teste ao longo das épocas – Arquitetura 1.




Figura 2: Acurácia de treino e teste ao longo das épocas – Arquitetura 2.




Figura 3: Comparação da acurácia de teste entre as duas arquiteturas.

4.2 Acurácia final e síntese

A Tabela 2 apresenta a acurácia final obtida por cada arquitetura no conjunto de teste.

Tabela 2: Síntese dos resultados no conjunto de teste (120 amostras)

Arquitetura	Blocos conv.	Acurácia (%)
Arquitetura 1	1	80,83
Arquitetura 2	3	95,83

A Arquitetura 1 atingiu 80,83% de acurácia, apresentando oscilações durante o treinamento e sinais de capacidade limitada com apenas um bloco convolucional. A Arquitetura 2 superou a meta de 95%, alcançando **95,83%** de acurácia, graças à maior profundidade da rede e ao aumento progressivo de filtros, que permitiu extrair representações mais discriminativas das faces.

5 Codificação

O código completo da solução está disponível no Google Colab pelo link:

https://colab.research.google.com/drive/1UqAnkoVBI5Q_9KyCQdempCb505vtg61E?usp=sharing