

Utilizando Redes Recorrentes (LSTM) para Reconhecimento de Atividades Humanas na Base UniMiB SHAR

Inteligência Artificial – 2026/1

Maria Giovanna Gonçalves Sales

1 Base de Dados

A base UniMiB SHAR contém registros de aceleração tridimensional (eixos x , y e z) coletados por meio do smartphone Samsung Galaxy Nexus I9250, equipado com sensor Bosh BMA220, sob o sistema operacional Android 5.1.1.

O conjunto empregado neste trabalho compreende 1 724 amostras distribuídas entre 9 atividades motoras:

1. **StandingUpFS** – levantando de uma cadeira (42 amostras)
2. **StandingUpFL** – levantando da cama (46 amostras)
3. **Walking** – caminhando (373 amostras)
4. **Running** – correndo (416 amostras)
5. **GoingUpS** – subindo escada (258 amostras)
6. **Jumping** – pulando (164 amostras)
7. **GoingDownS** – descendo escada (308 amostras)
8. **LyingDownFS** – deitando na cama (62 amostras)
9. **SittingDown** – sentando (55 amostras)

Cada amostra é descrita por 453 valores em ponto flutuante, correspondendo a 151 instantes de tempo de cada um dos três eixos do acelerômetro.

Dividimos a base em 85% para treinamento (1 465 amostras) e 15% para validação (259 amostras) de forma estratificada por classe e com semente de reprodutibilidade 42.

2 Pré-processamento

Os dados foram reorganizados do formato plano (1724×453) para o formato tridimensional ($1724 \times 151 \times 3$), em que as três dimensões representam, respectivamente, o número de amostras, os instantes de tempo e os eixos do acelerômetro.

Em seguida, cada eixo foi normalizado independentemente com média zero e desvio padrão unitário por meio do **StandardScaler**.

Os rótulos, originalmente inteiros de 1 a 9, foram convertidos para o intervalo $[0, 8]$ e codificados em formato *one-hot*.

3 Arquitetura da Rede

Foi implementada uma rede LSTM (*Long Short-Term Memory*) utilizando TensorFlow/Keras.

A arquitetura empilha dois blocos recorrentes seguidos de uma camada totalmente conectada:

$$\underbrace{\text{LSTM}_{128} \rightarrow \text{BN} \rightarrow \text{DO}_{0,3}}_{\text{bloco 1}} \rightarrow \underbrace{\text{LSTM}_{64} \rightarrow \text{BN} \rightarrow \text{DO}_{0,3}}_{\text{bloco 2}} \rightarrow \text{Dense}_{64} \rightarrow \text{DO}_{0,2} \rightarrow \text{Softmax}_9$$

onde BN denota Normalização em Lote (*Batch Normalization*) e DO_p denota Dropout com taxa p .

A primeira camada LSTM possui 128 unidades e opera com `return_sequences=True`, passando a sequência completa à próxima camada recorrente.

A segunda camada LSTM possui 64 unidades e opera com `return_sequences=False`, retornando apenas o estado final.

Cada bloco recorrente é seguido de Normalização em Lote e Dropout de 30% para controle de *overfitting*.

A camada densa intermediária possui 64 neurônios com ativação ReLU e Dropout de 20%, antecedendo a camada de saída com 9 neurônios e ativação *softmax*.

4 Hiperparâmetros

A Tabela 1 resume os hiperparâmetros utilizados no treinamento.

Table 1: Hiperparâmetros de treinamento

Hiperparâmetro	Valor
Épocas máximas	100
Tamanho do <i>batch</i>	32
Otimizador	Adam
<i>Learning rate</i> inicial	0,001
Função de perda	Entropia cruzada categórica
Dropout (blocos LSTM)	0,3
Dropout (camada densa)	0,2
Unidades LSTM (bloco 1)	128
Unidades LSTM (bloco 2)	64
Neurônios FC	64
Paciência EarlyStopping	15 épocas
Paciência ReduceLRonPlateau	7 épocas (fator 0,5)
<i>Seed</i> de reprodutibilidade	42

Dois *callbacks* foram utilizados durante o treinamento.

O `EarlyStopping` monitorou a acurácia de validação e interrompeu o treinamento caso não houvesse melhora por 15 épocas consecutivas, restaurando os pesos da melhor época.

O `ReduceLRonPlateau` reduziu o *learning rate* pela metade sempre que a perda de validação estagnou por 7 épocas, com valor mínimo de 10^{-6} .

5 Resultados

5.1 Curvas de treinamento

O treinamento foi interrompido pelo **EarlyStopping** na época 55, sendo restaurados os pesos da época 40 – aquela com maior acurácia de validação.

A Figura 1 mostra a evolução da acurácia de treino e validação ao longo das épocas.




Figure 1: Evolução da acurácia de treino e validação ao longo das épocas.

A Figura 2 exibe a curva de perda (*loss*), evidenciando redução progressiva e comportamento estável ao final do treinamento.




Figure 2: Evolução da perda (loss) de treino e validação ao longo das épocas.

5.2 Acurácia final

A Tabela 2 apresenta a acurácia e a perda obtidas no conjunto de validação (259 amostras).

Table 2: Resultados no conjunto de validação (259 amostras)

Modelo	Acurácia (%)	Loss
LSTM (128 $\rightarrow$ 64)	93,82	0,2134

5.3 Relatório de classificação por atividade

A Tabela 3 detalha as métricas de precisão, revocação e F1-score por classe.

Table 3: Relatório de classificação por atividade (validação)

Atividade	Precisão	Revocação	F1	Suporte
StandingUpFS	1,00	0,67	0,80	6
StandingUpFL	0,67	0,57	0,62	7
Walking	1,00	0,98	0,99	56
Running	1,00	1,00	1,00	63
GoingUpS	1,00	0,90	0,95	39
Jumping	0,96	0,96	0,96	25
GoingDownS	0,87	1,00	0,93	46
LyingDownFS	0,64	0,78	0,70	9
SittingDown	0,71	0,62	0,67	8
<i>accuracy</i>		0,94		259
macro avg	0,87	0,83	0,85	259
weighted avg	0,94	0,94	0,94	259

As atividades com maior número de amostras – Walking, Running, GoingUpS e Jumping – obtiveram desempenho bom, com F1-score acima de 0,95.

As menores métricas foram observadas em StandingUpFL, LyingDownFS e SittingDown, classes com poucas amostras, o que torna as estimativas mais sensíveis aos erros.

5.4 Matriz de confusão

A Figura 3 apresenta a matriz de confusão calculada sobre o conjunto de validação.

6 Codificação

O código completo da solução está disponível no Google Colab pelo link:

<https://colab.research.google.com/drive/1SzisMALgS2ABnxwr5QwW30CBkpWtsAEw?usp=sharing>




Figure 3: Matriz de confusão no conjunto de validação.